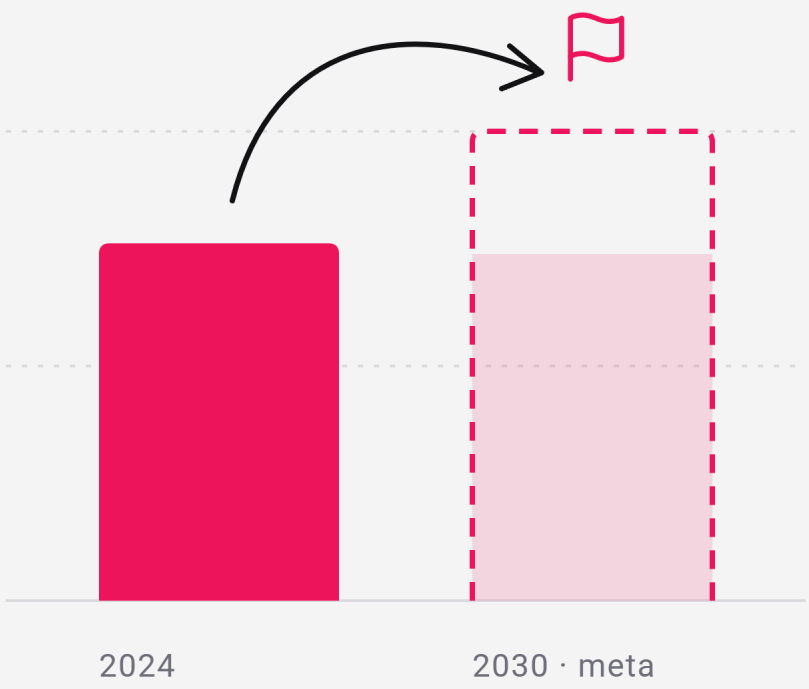
TECH CHALLENGE · FASE 3

# Alfabetização no Brasil: previsão de risco por município

Predição e inteligência analítica a partir do Indicador Criança Alfabetizada

Pós Tech AI Scientist
Eric Almeida · 2IAST

# Resultado oficial sai após o ano letivo



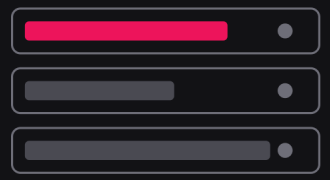

**59%**
REDE PÚBLICA · 2024
das crianças alfabetizadas ao fim do 2º ano

**80%**
META NACIONAL · 2030
a meta que o país assumiu

**47%**
MUNICÍPIOS · 2024
ficaram abaixo da própria meta

A avaliação acontece uma vez por ano e o resultado sai meses depois. Dá para saber antes?

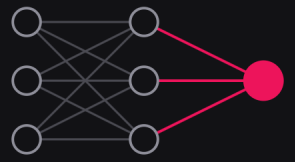
# Visão geral do projeto



01

**Dados**

3,9 milhões de alunos da camada Gold (Fase 2), mais IBGE e Inep (Censo Escolar, Saeb, Inse)



02

**Modelo**

Usa o resultado do ano anterior, o território e o contexto: a prova de 2023 prevê a de 2024



03

**Risco**

A chance de cada criança não se alfabetizar, somada por cidade e comparada com a meta

**O QUE O MODELO PREVÊ**

Para cada criança do 2º ano, a chance de não se alfabetizar (alvo: 1 = não alfabetizada, 0 = alfabetizada)

**COMO VIRA DECISÃO**

A média das crianças de cada cidade dá a taxa prevista, que é comparada com a meta

O passado prevê o futuro: a prova de 2023 prevê a de 2024.

# Como o modelo foi validado

01

## Análise exploratória

8 hipóteses que guiaram as escolhas

02

## O passado prevê o futuro

a prova de 2023 prevê 2024; a de 2024 prevê 2025

03

## Pipeline do scikit-learn

nulos, padronização e codificação aprendidos só no treino

04

## Teste em cidades novas

1.101 municípios separados desde o início

05

## Ajuste e escolha

5 modelos, Optuna, o mais simples entre os empatados

06

## Explicação

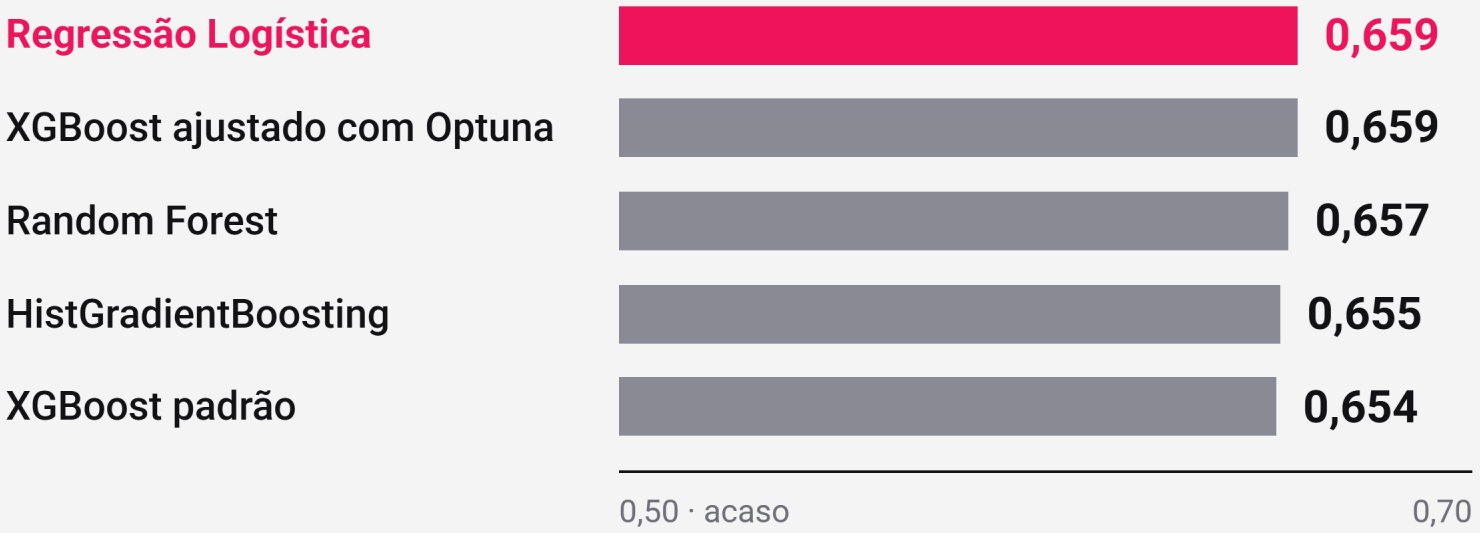
SHAP e permutation importance mostram o que pesa

Mesmo sabendo o resultado real de cada município, ninguém passaria muito do nosso acerto.

# Modelos usados

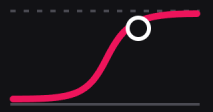
SUPERVISIONADOS COMPARADOS

Acerto (AUC) em municípios fora do treino




SUPERVISIONADO

## Regressão Logística



classificação

Dá um peso a cada variável da criança e transforma a soma numa probabilidade de 0 a 100%. Escolhida entre 5 modelos; o XGBoost ajustado com Optuna (30 combinações) empatou.

NÃO SUPERVISIONADO

## K-Means



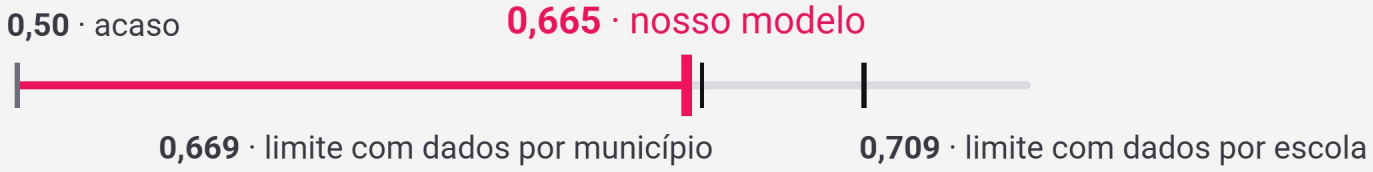
agrupamento

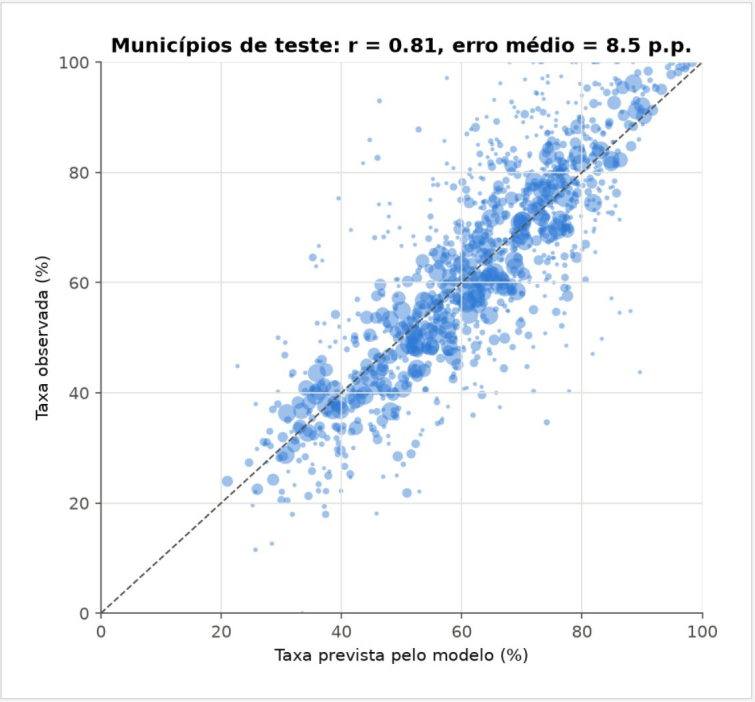
Junta municípios parecidos em perfis, sem alvo. Resultado no slide 10.

• • Os supervisionados empataram; a regressão logística é a mais fácil de explicar.

# Resultados do modelo

| | PREVISTO: ALFABETIZADO | PREVISTO: EM RISCO |
|---|---|---|
| **Real: alfabetizado** | **31%** acertou | **69%** alerta a mais |
| **Real: não alfabetizado** | **12%** deixou passar | **88%** encontrou |




| AUC | RECALL | PRECISÃO | F1 | BRIER | LOG LOSS | MUNICÍPIO |
|---|---|---|---|---|---|---|
| **0,665** | **88%** | **47%** | **0,62** | **0,224** | **0,637** | **0,81** |
| chute: 0,500 | acha os em risco | chute: 42% | chute: 0,59 | chute: 0,243 | chute: 0,679 | correlação · erro de 8,5 pontos |

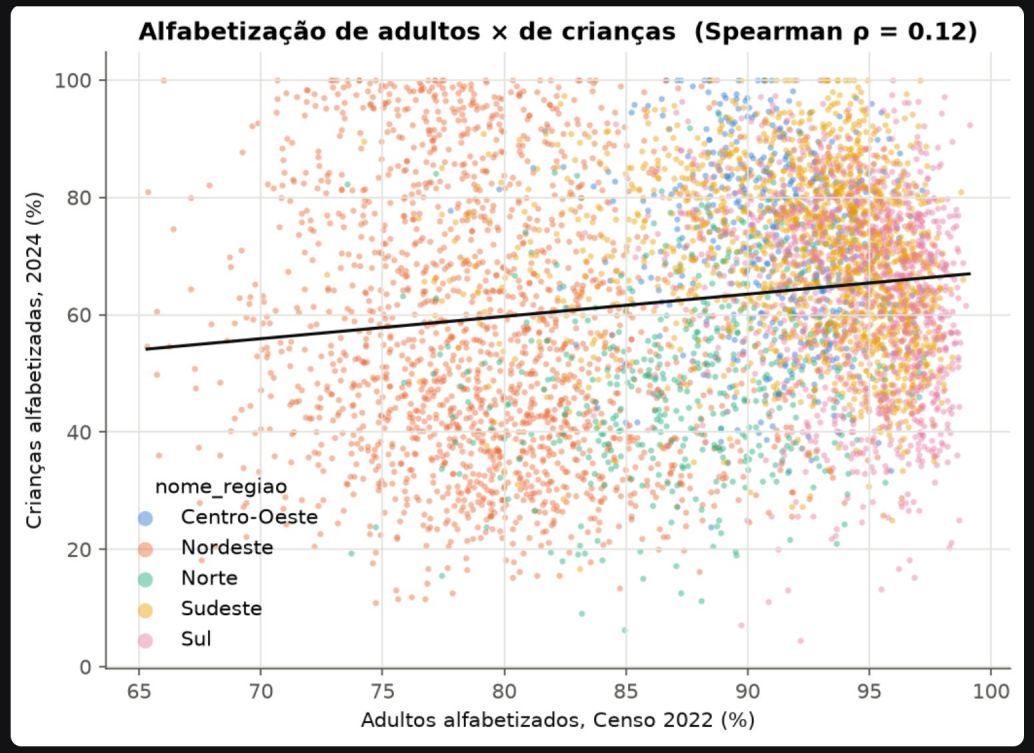
AUC 0,665 no teste · 356 mil alunos · 1.101 municípios

# Resumo dos achados

| | | |
|---|---|---|
| 01 | **A renda não define o resultado** | Dentro das regiões, cidades mais ricas não alfabetizam mais (Ceará: 93%) |
| 02 | **O que mais pesa é a qualidade da rede** | Cerca de 58% da previsão; a renda pesa 8% |
| 03 | **Um grupo de municípios parou** | O interior pouco povoado e de renda mais alta caiu 1 ponto de 2023 para 2024 |
| 04 | **Repetir o ano anterior engana** | Os piores subiram 12 pontos e os melhores caíram 9; a regra ingênua acerta 48% |
| 05 | **A meta de 2025 é bem mais difícil** | Metade dos municípios tem taxa prevista abaixo dela |

As três primeiras, em detalhe, nos próximos slides

# Renda e alfabetização: correlação baixa




CEARÁ

Uma das populações adultas menos escolarizadas do país

**93%**

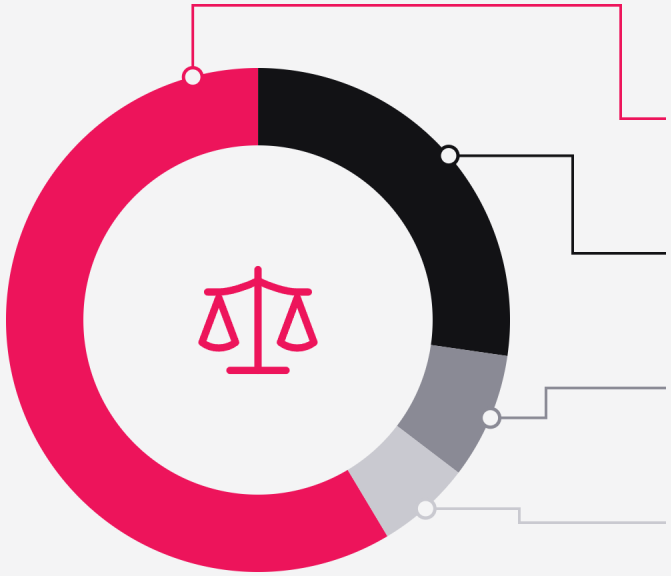
das crianças alfabetizadas (mediana dos municípios)

Correlação quase nula: ρ de Spearman = 0,12

## A política faz diferença.

Alfabetização de adultos (Censo 2022) × crianças (2024), por município

# Fatores que mais pesam no risco



| | |
|---|---|
| **Qualidade da rede no ano anterior** | **58%** |
| Estado e região | **27%** |
| Renda e contexto do município | **8%** |
| Rede estadual ou municipal | **6%** |

A taxa de alfabetização da rede e o Ideb do 5º ano são as duas variáveis que mais pesam. O resultado de hoje é o melhor sinal do de amanhã, e por isso dá para agir cedo.

Peso de cada grupo de fatores na previsão · análise SHAP

# Perfis de municípios

K-Means com 9 variáveis por município: taxa, variação, participação, diferença entre escolas, adultos alfabetizados, PIB, urbanização, saneamento e densidade. 3 perfis.

| | Alto analfabetismo adulto | Interior pouco povoado | Urbano com infraestrutura |
|---|---|---|---|
| Adultos analfabetos | 21% | 8% | 6% |
| PIB per capita | R$ 12 mil | R$ 38 mil | R$ 33 mil |
| % urbana | 57% | 65% | 90% |
| Esgoto adequado | 16% | 6% | 79% |

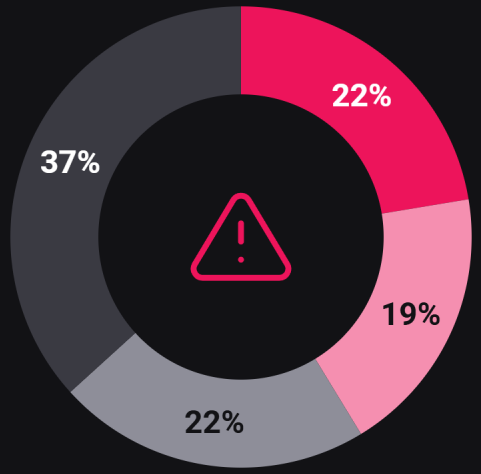
Medianas dos municípios de cada perfil.

| PERFIL | VARIAÇÃO 2023 → 2024 (PONTOS) | TAXA 2024 |
|---|---|---|
| **Alto analfabetismo adulto e pouca infraestrutura**<br>1.868 municípios · 86% do Nordeste | +2,9 | 55,8% |
| **Interior pouco povoado e de renda mais alta**<br>1.569 municípios · Centro-Oeste, Sul e Norte | −0,7 | 66,7% |
| **Urbano com infraestrutura**<br>1.795 municípios · 75% do Sudeste | +4,4 | 67,8% |

**O interior pouco povoado é o perfil mais rico, com o triplo da renda do perfil nordestino, e foi o único que não melhorou.**

Perfis por agrupamento K-Means · variação de 2023 para 2024, em pontos

# 2.210 municípios em risco em 2025



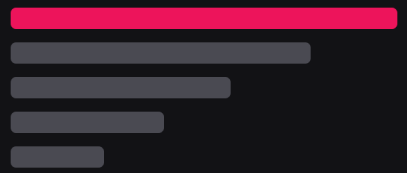

| | |
|---|---|
| **Muito alto** | **1.198** |
| **Alto** | **1.012** |
| Moderado | 1.176 |
| Baixo | 1.966 |

% DE MUNICÍPIOS EM RISCO ALTO, POR ESTADO




Rio Grande do Sul (93%) marcado à parte: a queda de 2024 pode ter relação com as enchentes.

# Como usar



01

## Priorizar apoio

Começar pelos municípios de risco muito alto, antes de o resultado sair



02

## Política por perfil

Aproximar quem alfabetiza bem de quem tem dificuldade; programas no interior pouco povoado



03

## Agir antes, todo ano

Rodar a análise logo que sai o resultado anterior

**O modelo mostra onde está o risco, não a causa. Serve para apoiar, não para punir.**

TECH CHALLENGE · FASE 3

# Obrigado!

Pós Tech AI Scientist
Eric Almeida · 2IAST